

Chapter 16: ডেটা লেক (Data Lake)

ডেটা লেক কী?

ডেটা লেক (Data Lake) হলো একটি কেন্দ্রীয় (Centralized) ডেটা স্টোরেজ, যেখানে **Structured, Semi-Structured** এবং **Unstructured**—সব ধরনের ডেটা তাদের **Raw (মূল)** অবস্থায় সংরক্ষণ করা হয়। পরবর্তীতে প্রয়োজন অনুযায়ী সেই ডেটা বিশ্লেষণ, প্রসেসিং এবং Machine Learning-এর জন্য ব্যবহার করা হয়।

সহজভাবে বলতে গেলে,

Data Lake হলো এমন একটি বিশাল ডেটা সংগ্রহশালা, যেখানে বিভিন্ন উৎস থেকে আসা সব ধরনের ডেটা কোনো নির্দিষ্ট Schema ছাড়াই Raw আকারে সংরক্ষণ করা হয়।

কেন Data Lake প্রয়োজন?

ধরুন, একটি E-commerce কোম্পানির বিভিন্ন উৎস থেকে ডেটা আসছে—

- Website Click Data
- Mobile App Data
- Customer Information
- Sales Data
- Payment Data
- Product Images
- Product Videos
- Social Media Data
- IoT Device Data
- Server Logs

এই সব ডেটা একই ধরনের নয়।

- Customer Information → Structured
- JSON API Response → Semi-Structured
- Image, Video, Audio → Unstructured

এগুলোকে একটি Relational Database-এ সংরক্ষণ করা কঠিন এবং ব্যয়বহুল হতে পারে।

এক্ষেত্রে **Data Lake** সবচেয়ে উপযুক্ত সমাধান।

Data Lake-এর বৈশিষ্ট্য

১. সব ধরনের ডেটা সংরক্ষণ করতে পারে

- Structured
- Semi-Structured
- Unstructured

২. Raw Data সংরক্ষণ করে

ডেটা আগে থেকে পরিবর্তন বা রূপান্তর (Transform) করা হয় না।

প্রয়োজন হলে পরে প্রসেস করা হয়।

৩. Schema-on-Read


Data Warehouse-এর মতো **Schema-on-Write** নয়।

Data Lake-এ ডেটা সংরক্ষণের সময় Schema প্রয়োজন হয় না। ডেটা পড়ার (Read) সময় Schema প্রয়োগ করা হয়।

৪. Highly Scalable

প্রয়োজন অনুযায়ী সহজেই Petabyte বা তারও বেশি ডেটা সংরক্ষণ করা যায়।

Data Lake Architecture



Data Lake-এ কী ধরনের ডেটা রাখা যায়?

ডেটার ধরন	উদাহরণ
Structured	Customer, Orders
Semi-Structured	JSON, XML, CSV
Unstructured	Image, Video, Audio, PDF
Streaming Data	IoT Sensor, Kafka Stream
Log Data	Web Server Log, Application Log

Data Lake বনাম Data Warehouse

বিষয়	Data Lake	Data Warehouse
ডেটার ধরন	সব ধরনের ডেটা	মূলত Structured Data
ডেটা	Raw Data	Processed Data
Schema	Schema-on-Read	Schema-on-Write
ব্যবহার	Data Science, AI, ML, Big Data	Reporting, BI, Analytics
Storage Cost	কম	তুলনামূলক বেশি
Processing	পরে করা হয়	আগে করা হয়

Data Lake বনাম Data Warehouse বনাম Data Mart

বিষয়	Data Lake	Data Warehouse	Data Mart
ডেটা	Raw	Processed	Department-specific
Schema	Read-এর সময়	Write-এর সময়	Warehouse-এর অংশ
ব্যবহারকারী	Data Engineer, Data Scientist	Business Analyst	নির্দিষ্ট বিভাগ
উদ্দেশ্য	Data Storage	Analytics	Department Reporting

বাস্তব উদাহরণ

ধরুন, একটি Ride Sharing কোম্পানি (যেমন Uber-এর মতো) প্রতিদিন নিচের ডেটা সংগ্রহ করে—

- Ride Information
- GPS Location

- Mobile App Click
- Driver Information
- Customer Review
- Payment History
- Vehicle Image
- Call Recording

এই সব ডেটা প্রথমে **Data Lake**-এ Raw অবস্থায় সংরক্ষণ করা হয়।

এরপর—

- Business Report তৈরির জন্য প্রয়োজনীয় ডেটা **Data Warehouse**-এ পাঠানো হয়।
- Machine Learning Model তৈরির জন্য Data Scientist একই Data Lake থেকে ডেটা ব্যবহার করেন।
- Fraud Detection ও Recommendation System-ও Data Lake-এর ডেটা ব্যবহার করতে পারে।

জনপ্রিয় Data Lake প্রযুক্তি

Cloud

- Amazon S3
- Azure Data Lake Storage (ADLS)
- Google Cloud Storage (GCS)

Big Data Platform

- Hadoop HDFS
- Apache Iceberg
- Delta Lake
- Apache Hudi

Data Lake-এর সুবিধা

- সব ধরনের ডেটা সংরক্ষণ করা যায়।
- কম খরচে বিশাল পরিমাণ ডেটা রাখা যায়।
- Machine Learning ও AI-এর জন্য উপযুক্ত।
- Big Data Analytics সহজ হয়।
- ভবিষ্যতের বিশ্লেষণের জন্য Raw Data সংরক্ষণ করা যায়।
- সহজে স্কেল করা যায়।

Data Lake-এর সীমাবদ্ধতা

- সঠিক Governance না থাকলে এটি **Data Swamp**-এ পরিণত হতে পারে (অর্থাৎ, এলোমেলো ও অপ্রয়োজনীয় ডেটার স্তুপ)।
- Data Quality নিশ্চিত করা কঠিন।
- Security ও Access Control সঠিকভাবে পরিকল্পনা করতে হয়।
- Metadata Management প্রয়োজন।

উপসংহার

Data Lake হলো একটি কেন্দ্রীয় স্টোরেজ যেখানে Structured, Semi-Structured এবং Unstructured—সব ধরনের ডেটা Raw অবস্থায় সংরক্ষণ করা হয়। এটি Big Data, Machine Learning, Artificial Intelligence এবং Advanced Analytics-এর জন্য অত্যন্ত গুরুত্বপূর্ণ। আধুনিক Data Architecture-এ সাধারণত **Data Lake** Raw Data সংরক্ষণ করে এবং সেখান থেকে প্রয়োজনীয় ডেটা **Data Warehouse** ও **Data Mart**-এ পাঠিয়ে Business Intelligence ও Reporting পরিচালনা করা হয়।